

HandsOn 02 – MapReduce untuk Data Tabel


Diberikan dataset yang sama, “purchases.txt”, yang digunakan di *Example 02* pada slide, buatlah program map reduce untuk masing-masing milestone di bawah ini. Untuk menjalankan map reduce di Hadoop, file “purchases.txt” tersebut harus sudah ditempatkan di suatu folder di HDFS. Sebelumnya, pastikan Hadoop sudah berjalan di VM yang digunakan (seperti yang telah dilakukan di HandsOn 01 sebelumnya).

A. Milestone 1

1. Tampilkan total nilai penjualan untuk produk: (i) “Toys” dan (ii) “Consumer Electronics”. Sebagai catatan, nama produk dapat bermacam-macam, selama mengandung salah satu dari kedua string, (i) dan (ii), tersebut. Contoh: “Buffalo Toys”. Output dari milestone ini adalah sebagai berikut.

Consumer Electronics	57452374.13000056
Toys	57463477.109998636

2. Tampilkan hasil MapReducenya dalam terminal menggunakan perintah `hdfs dfs -cat /folder_output_kamu/file_output`, dan pastekan screenshotnya di bawah.



```

2026-03-16 08:29:27,417 INFO streaming.StreamJob: Output directory: /user/output_milestone1
[root@namenode /]# hdfs dfs -cat /user/output_milestone1/part-*
2026-03-16 08:29:37,728 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Consumer Electronics    57452374.13000056
Toys                    57463477.109998636

```

Catatan: semua file python mapper dan reducer yang digunakan selama HandsOn ini, dibutuhkan untuk disubmit. Baca detail format pengumpulannya di bagian paling bawah dari dokumen ini.

B. Milestone 2:

1. Tampilkan nilai penjualan tertinggi beserta item produknya¹ untuk masing-masing toko yang berada di kota: **Miami**, **San Francisco** dan **Atlanta**. Output dari milestone ini adalah sebagai berikut.

Atlanta	499.96	Pet Supplies
Miami	499.98	Video Games
San Francisco	499.97	Men's Clothing

2. Tampilkan hasil MapReducenya dalam terminal menggunakan perintah `hdfs dfs -cat /folder_output_kamu/file_output`, dan pastekan screenshotnya di bawah.

¹ Bisa jadi penjualan tertinggi nilainya tidak unik dan terdapat pada beberapa produk. Pada kasus yang demikian, kamu hanya perlu mencantumkan salah satu produknya saja

```

[root@namenode /]# hdfs dfs -cat /user/output_milestone2/part-*
2026-03-16 08:34:36,576 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Atlanta 499.96 Pet Supplies
Miami 499.98 Video Games
San Francisco 499.97 Men's Clothing

```

C. Milestone 3:

1. Tampilkan banyaknya penjualan yang terjadi di rentang jam 09:01-10:00 dan jam 10:01-11:00. Output dari milestone ini adalah sebagai berikut.

09:01-10:00	459775
10:01-11:00	459825

3. Tampilkan hasil MapReducenya dalam terminal menggunakan perintah `hdfs dfs -cat /folder_output_kamu/file_output`, dan pastekan screenshotnya di bawah.

```

[root@namenode /]# hdfs dfs -cat /user/output_milestone3/part-*
2026-03-16 08:37:30,088 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
09:01-10:00 459775
10:01-11:00 459825
[root@namenode /]#

```

Pesan antara:

Implementasi MapReduce dengan membuat file kode secara *custom* untuk mapper dan reducer yang dilakukan di atas memberikan keleluasaan programmer untuk mengembangkan programnya. Akan tetapi, hal tersebut memang diperlukan usaha yang relatif besar untuk membawa permasalahan-permasalahan yang diberikan ke paradigma “map” dan “reduce”. Usaha ini sebanding dengan keuntungan yang bisa kita dapatkan, yaitu mampu mendistribusikan komputasi ke mesin-mesin dalam kluster.

Di dalam ekosistem Hadoop, tersedia sebuah *tool* yang mengubah *SQL-like query* ke komputasi MapReduce yang kemudian dapat didistribusikan ke dalam kluster, yaitu Apache Hive. Dengan menggunakan Apache Hive, seorang programmer dapat mengolah data tabel yang tersimpan (terdistribusi) di kluster layaknya melakukan *query* menggunakan SQL. Sekali lagi, query tersebut kemudian akan dikonversikan ke MapReduce dan akan memproses datanya secara terdistribusi di dalam kluster.

D. Milestone 4

1. Masuk ke Hive dengan cara seperti yang telah dilakukan di HandsOn 01
2. Buatlah tabel “purchases” dari data “purchases.txt” yang telah disimpan di HDFS. Sebagai referensi, untuk membuat tabel “mahasiswa” dari file (dengan tiga kolom, terpisah dengan koma) yang berada di folder HDFS “/mahasiswa”, dapat dilakukan dengan kode berikut.

```
CREATE TABLE IF NOT EXISTS mahasiswa(ID int, nama string, ipk float)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ','
STORED AS TEXTFILE
LOCATION '/mahasiswa/';
```

- Setelah tabel “purchases” terbuat, tes dengan query `select * from purchases limit 10;`
- Ambil screenshot (hasil query-nya) dan pastekan di bawah ini.

```
INFO : 2026-03-24 03:11:45,515 Stage-1 map = 100%, reduce = 0%, Cumulative CPU 0.55 sec
INFO : MapReduce Total cumulative CPU time: 550 msec
INFO : Ended Job = job_local995384915_0001
INFO : MapReduce Jobs Launched:
INFO : Stage-Stage-1: Cumulative CPU: 0.55 sec HDFS Read: 110592 HDFS Write: 736 HDFS EC Read: 0 SUCCESS
INFO : Total MapReduce CPU Time Spent: 550 msec
INFO : Completed executing command(queryId=hive_20260324031137_7b8cf415-781e-43ee-8f99-eee5368b4351); Time taken: 4.025 seconds
```

purchases.purchase_date	purchases.purchase_time	purchases.city	purchases.category	purchases.amount
2012-01-01	09:00	San Jose	Men's Clothing	214.05
2012-01-01	09:00	Fort Worth	Women's Clothing	153.57
2012-01-01	09:00	San Diego	Music	66.08
2012-01-01	09:00	Pittsburgh	Pet Supplies	493.51
2012-01-01	09:00	Omaha	Children's Clothing	235.63
2012-01-01	09:00	Stockton	Men's Clothing	247.18
2012-01-01	09:00	Austin	Cameras	379.6
2012-01-01	09:00	New York	Consumer Electronics	296.8
2012-01-01	09:00	Corpus Christi	Toys	25.38
2012-01-01	09:00	Fort Worth	Toys	213.88

```
10 rows selected (8.016 seconds)
```

E. Milestone 5

- Lakukan Milestone 1, akan tetapi menggunakan query Hive dari tabel “purchases” yang telah dibuat.²
- Ambil screenshot (bagian ekspresi SQL dan hasil query-nya), dan pastekan di bawah ini. Hasil Milestone 1 dan 5 seharusnya memberikan keluaran yang sama³.

```
SELECT purchases.category AS category, SUM(purchases.amount) AS
total_purchase_amount
FROM purchases
WHERE purchases.category LIKE 'Toys' OR purchases.category LIKE 'Consumer
Electronics'
```

² Bagi VM dengan size RAM kecil, kemungkinan proses akan terhenti di tengah. Jika tidak memungkinkan untuk menambahkan size RAM di VM, ambil screenshot “ekspresi SQL yang kamu buat” dan “pesan errornya”.

³ Hiraukan perbedaan minor string “lowercase” dan “Capital Each Word”.

```
GROUP BY purchases.category;
```

```
INFO : 2026-03-24 03:33:06,556 Stage-1 map = 0%, reduce = 0%
INFO : 2026-03-24 03:33:07,565 Stage-1 map = 100%, reduce = 100%, Cumulative CPU 1.93 sec
INFO : MapReduce Total cumulative CPU time: 1 seconds 930 msec
INFO : Ended Job = job_local1647293928_0004
INFO : MapReduce Jobs Launched:
INFO : Stage-Stage-1: Cumulative CPU: 1.93 sec HDFS Read: 1268125432 HDFS Write: 2305 HDFS EC Read: 0 SUCCESS
INFO : Total MapReduce CPU Time Spent: 1 seconds 930 msec
INFO : Completed executing command(queryId=hive_20260324033304_abf5c19a-f8b3-4ee6-a5bc-929ee29cd612); Time taken: 2.946 seconds
```

category	total_purchase_amount
Consumer Electronics	5.745237412999909E7
Toys	5.746347710999907E7

```
2 rows selected (3.177 seconds)
```

F. Milestone 6

1. Lakukan Milestone 2, akan tetapi menggunakan query Hive dari tabel “purchases” yang telah dibuat.
2. Ambil screenshot (bagian ekspresi SQL dan hasil query-nya), dan pastekan di bawah ini. Hasil Milestone 2 dan 6 seharusnya memberikan keluaran yang sama.

```
WITH max_purchase_amount_per_city AS (
SELECT city, MAX(amount) AS amount
FROM purchases
GROUP BY city)
SELECT p.city AS city, m.amount AS max_purchase_amount, p.category as category
FROM purchases p
JOIN max_purchase_amount_per_city m ON p.city = m.city
WHERE p.city IN ('Miami', 'San Francisco', 'Atlanta') AND p.amount = m.amount;
```

```
INFO : 2026-03-24 04:02:20,140 Stage-1 map = 0%, reduce = 0%
INFO : 2026-03-24 04:02:21,144 Stage-1 map = 100%, reduce = 0%, Cumulative CPU 2.39 sec
INFO : 2026-03-24 04:02:22,149 Stage-1 map = 100%, reduce = 100%, Cumulative CPU 2.58 sec
INFO : MapReduce Total cumulative CPU time: 2 seconds 580 msec
INFO : Ended Job = job_local2084146143_0012
INFO : MapReduce Jobs Launched:
INFO : Stage-Stage-2: Cumulative CPU: 3.31 sec HDFS Read: 4233371342 HDFS Write: 6809758 HDFS EC Read: 0 SUCCESS
INFO : Stage-Stage-1: Cumulative CPU: 2.58 sec HDFS Read: 6984008073 HDFS Write: 10214889 HDFS EC Read: 0 SUCCESS
INFO : Total MapReduce CPU Time Spent: 5 seconds 890 msec
INFO : Completed executing command(queryId=hive_20260324040214_1a4c8aac-1f79-4a8d-9ed0-f80c9ae8e199); Time taken: 6.978 seconds
```

city	max_purchase_amount	p.category
Atlanta	499.96	Pet Supplies
Miami	499.98	Video Games
Miami	499.98	Men's Clothing
San Francisco	499.97	Men's Clothing

```
4 rows selected (7.265 seconds)
```

G. Milestone 7

1. Lakukan Milestone 3, akan tetapi menggunakan query Hive dari tabel “purchases” yang telah dibuat.
2. Ambil screenshot (bagian ekspresi SQL dan hasil query-nya), dan pastekan di bawah ini. Hasil Milestone 3 dan 7 seharusnya memberikan keluaran yang sama.

```
SELECT
SUM(CASE WHEN (hour(purchase_time) = 9 AND minute(purchase_time) >= 1) OR
(hour(purchase_time) = 10 AND minute(purchase_time) = 0) THEN 1 ELSE 0 END) AS
sales_0901_1000,SUM(CASE WHEN (hour(purchase_time) = 10 AND
minute(purchase_time) >= 1) OR (hour(purchase_time) = 11 AND
minute(purchase_time) = 0) THEN 1 ELSE 0 END) AS sales_1001_1100
FROM purchases;
```

```
INFO : 2026-03-24 05:10:52,387 Stage-1 map = 0%, reduce = 0%
INFO : 2026-03-24 05:11:52,474 Stage-1 map = 0%, reduce = 0%, Cumulative CPU 66.05 sec
INFO : 2026-03-24 05:12:27,519 Stage-1 map = 42%, reduce = 0%, Cumulative CPU 104.32 sec
INFO : 2026-03-24 05:13:14,571 Stage-1 map = 100%, reduce = 100%, Cumulative CPU 153.65 sec
INFO : MapReduce Total cumulative CPU time: 2 minutes 33 seconds 650 msec
INFO : Ended Job = job_local807588234_0013
INFO : MapReduce Jobs Launched:
INFO : Stage-Stage-1: Cumulative CPU: 153.65 sec HDFS Read: 5078639926 HDFS Write: 6810375 HDFS EC Read: 0
SUCCESS
INFO : Total MapReduce CPU Time Spent: 2 minutes 33 seconds 650 msec
INFO : Completed executing command(queryId=hive_20260324051049_00f82666-b118-430c-a331-d5fd90e62458); Time taken: 144.363 seconds

+-----+-----+
| sales_0901_1000 | sales_1001_1100 |
+-----+-----+
| 459775          | 459825          |
+-----+-----+
1 row selected (145.146 seconds)
```

H. Milestone 8

1. Jika pada Milestone 5, 6 dan 7 hasil yang didapatkan tidak dapat menyamai⁴ dari Milestone 1, 2 dan 3, berikan analisa kamu. Jika alasannya adalah terkait keterbatasan SQL-like query, berikan ide/solusinya agar hasil dari Milestone 5, 6 dan 7 secara berturut-turut sama dengan Milestone 1, 2 dan 3.
Sudah sama

Setelah semua screenshot dipastekan di masing-masing milestone, upload file zip dengan nama: “HO_01_NIM_NamaLengkap.zip” ke form submission/assignment di **edunex** yang telah disediakan. Adapun isi dari file zipnya adalah:

1. File pdf dari dokumen ini, dengan nama: “HO_01_NIM_NamaLengkap.pdf”
2. File mapper dan reducer dari dari Milestone 1-3, dengan format nama “mapper_milestone1.py” dan “reducer_milestone1.py” untuk Milestone 1, begitu seterusnya hingga Milestone 3.

⁴ Hiraukan perbedaan minor string “lowercase” dan “Capital Each Word”.

--- done ---